

Introducción a ML y GenAI

Regresión Lineal

Ariel Ramos Vela

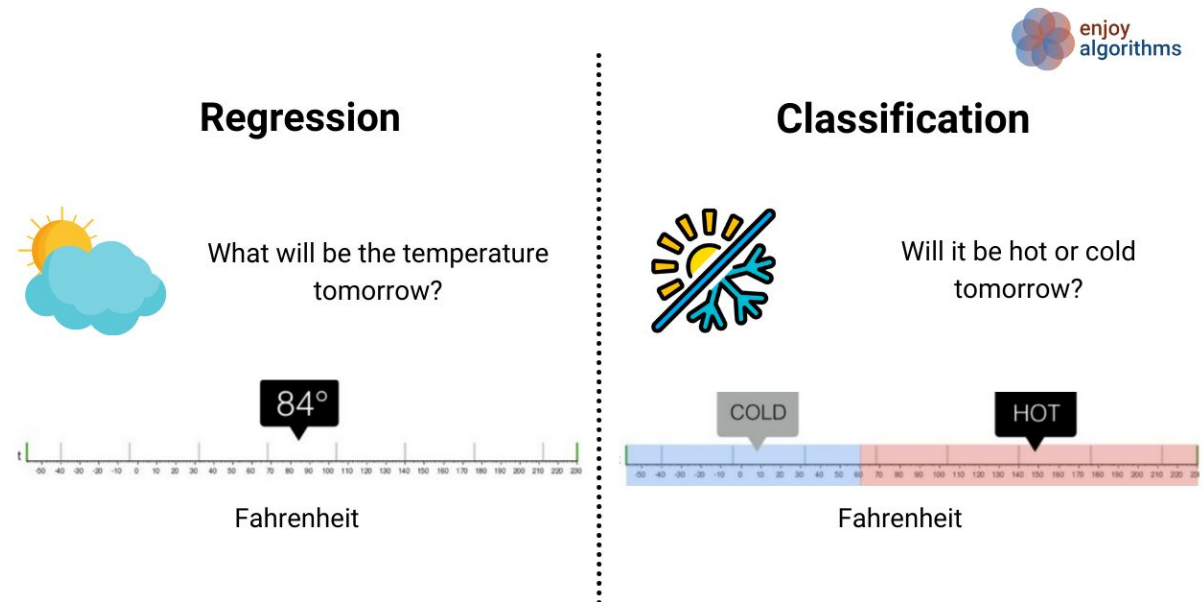
20-09-2024

Agenda

1. ¿Qué es la Regresión?
2. Introducción a la Regresión Lineal
3. La Función de Costo (Cost Function)
4. Descenso por Gradiente (Gradient Descent)
5. Métricas para Evaluar la Regresión
6. Taller 4: Ejemplo Práctico: Dataset Weights and Heights




¿Qué es la Regresión?

- **Definición:** La **regresión** es una técnica estadística que modela y analiza las relaciones entre variables. Busca predecir un valor continuo basado en una o más variables independientes.
- **Objetivo Principal:** Encontrar la relación entre una variable dependiente (output) y una o más variables independientes (input).



Tipos de Regresión

- **Regresión Lineal:** Predice un valor continuo basado en una relación lineal entre las variables.
- **Regresión Logística:** Para problemas de clasificación.
- **Regresión Polinomial:** Extiende la regresión lineal para modelar relaciones más complejas.




Introducción a la Regresión Lineal

- **Definición:** La regresión lineal busca modelar la relación entre una variable dependiente (Y) y una variable independiente (X), ajustando una línea recta a los datos.

$$y = mx + b$$

$$y = \theta_1 x + \theta_2$$




Introducción a la Regresión Lineal

- **Definición:** La regresión lineal busca modelar la relación entre una variable dependiente (Y) y una variable independiente (X), ajustando una línea recta a los datos.

$$y = mx + b$$

$$y = \theta_1 x + \theta_2$$

¿Y si tenemos más features (columnas)?



Introducción a la Regresión Lineal

- **Definición:** La regresión lineal busca modelar la relación entre una variable dependiente (Y) y una variable independiente (X), ajustando una línea recta a los datos.

$$y = mx + b$$


$$y = \theta_1 x + \theta_0$$

¿Y si tenemos más features (columnas)?

$$y = \theta_2 x_2 + \theta_1 x_1 + \theta_0$$

$$y = \theta_n x_n + \theta_{n-1} x_{n-1} + \theta_{n-2} x_{n-2} + \dots + \theta_1 x_1 + \theta_0$$


n features



Ejemplo: Altura (X) para predecir Peso (Y)

$$\hat{y} = \theta_1 x + \theta_0$$

- \hat{y} es el valor predicho (hipótesis).
- **Objetivo:** Minimizar la diferencia entre los valores predichos \hat{y} y los valores reales y .

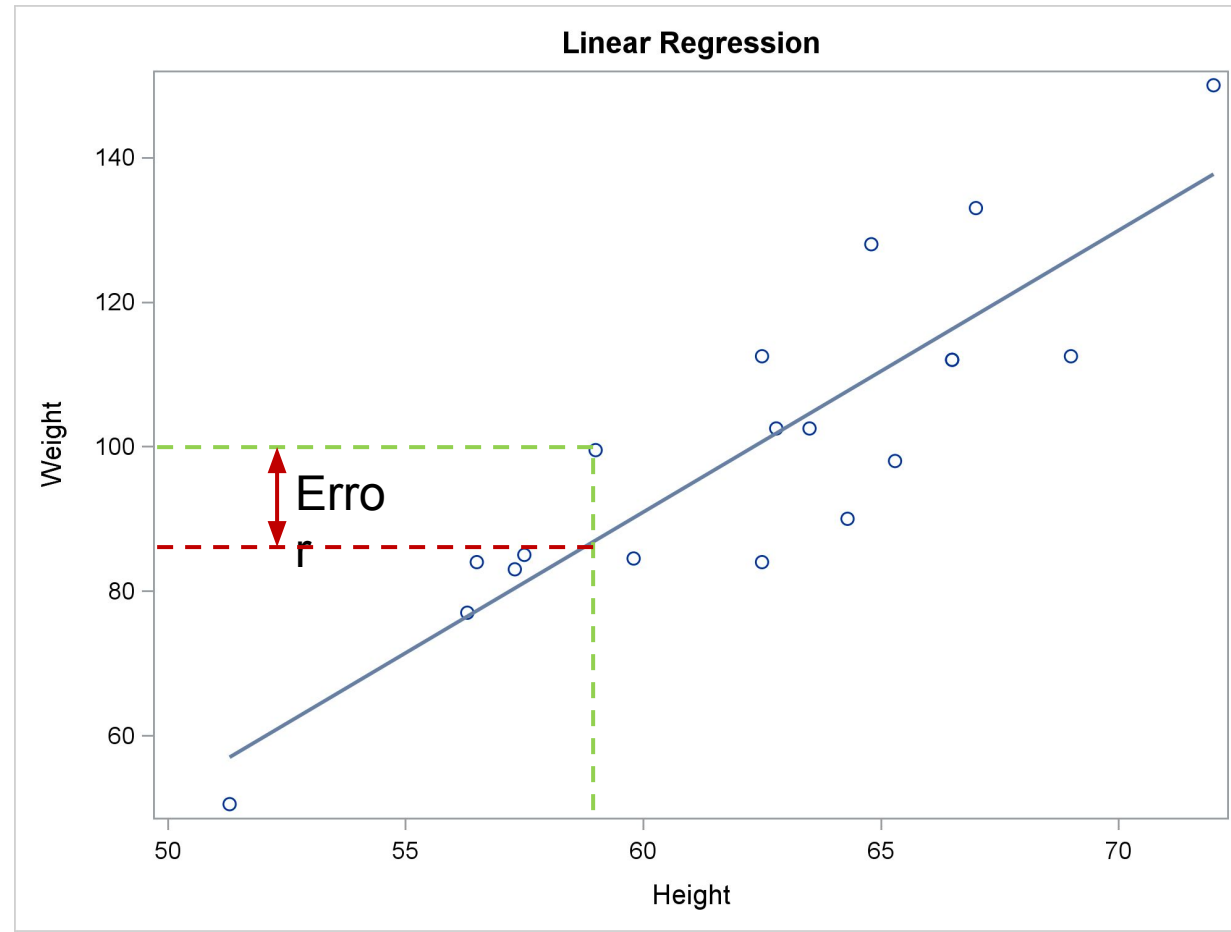


Ejemplo: Altura (X) para predecir Peso (Y)

$$\hat{y} = \theta_1 x + \theta_0$$

- \hat{y} es el valor predicho.
- **Objetivo:** Minimizar la diferencia entre los valores predichos \hat{y} y los valores reales y .

- \hat{y} (predicted) = 87
- $y = 100$




Ejemplo: Altura (X) para predecir Peso (Y)

$$\hat{y} = \theta_1 x + \theta_0$$

- \hat{y} es el valor predicho.
- **Objetivo:** Minimizar la diferencia entre los valores predichos \hat{y} y los valores reales y .

- \hat{y} (predicted) = 87
- $y = 100$

$$Cost = (y - \hat{y})^2$$



Ejemplo: Altura (X) para predecir Peso (Y)

$$\hat{y} = \theta_1 x + \theta_0$$


- \hat{y} es el valor predicho.
- **Objetivo:** Minimizar la diferencia entre los valores predichos \hat{y} y los valores reales y .

- \hat{y} (predicted) = 87
- $y = 100$

$$\text{cost} = (y - \hat{y})^2$$

$$\text{cost} = \frac{1}{2m} \sum_{i=1}^m (y - \hat{y})^2$$

m es el número de puntos que tenemos



Función de Costo (Cost Function)



- **Definición:** La función de costo cuantifica el error entre las predicciones del modelo y los valores reales.

$$cost = \frac{1}{2m} \sum_{i=1}^m (y - \hat{y})^2$$

- La meta es minimizar esta función para encontrar los mejores parámetros θ_0 y θ_1 .

$$\hat{y} = \theta_1 x + \theta_0$$


Visualización de la Función de Costo



$\alpha = \text{learning rate}$


$X = (m \text{ datapoints, } n' \text{ features})$

X
=



Shape =

$Y =$




Shape
=

$$\hat{y} = \theta_n x_n + \theta_{n-1} x_{n-1} + \theta_{n-2} x_{n-2} + \dots + \theta_1 x_1 + \theta_0$$

$$\hat{y} = X\theta \text{ (matrix form)}$$

$\theta =$



Shape

$$\hat{y} = X\theta$$

$$cost = \frac{1}{2m} \sum_{i=1}^m (y - \hat{y})^2$$

$\alpha = \text{learning rate}$
(taza de aprendizaje)

$$cost = \frac{1}{2m} \sum_{i=1}^m (Y - X\theta)^2$$

$$\frac{d(cost)}{d\theta} = 2 \frac{1}{2m} (Y - \hat{Y})X$$

$$\frac{d(cost)}{d\theta} = \frac{1}{m} X^T (Y - \hat{Y})$$

$$(n, m)(m, 1) = (n, 1)$$

Algoritmo

:

- Inicializar θ a cero.
- Bucle (loop) e.g. 1000 times

$$\hat{y} = X\theta$$

$$cost = \frac{1}{2m} * \text{sum}(Y - \hat{Y})^2$$

$$\frac{d(cost)}{d\theta} = \frac{1}{m} X^T (Y - \hat{Y})$$

$$\theta = \theta - \alpha * \frac{d(cost)}{d\theta}$$

Evaluación del Modelo: Métricas

- **Error Cuadrático Medio (MSE)**

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)})^2$$

- **Error Absoluto Medio (MAE):**

$$MAE = \frac{1}{m} \sum_{i=1}^m |\hat{y}^{(i)} - y^{(i)}|$$

- **R-cuadrado (R^2):**

- Evalúa qué tan bien el modelo explica la variabilidad de los datos.
- 1 indica un ajuste perfecto.
- 0 indica un modelo que no tiene ningún valor predictivo

$$R^2 = 1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$$

Ejemplo Práctico con Dataset "Weights and Heights"

- **Descripción del Dataset:**
 - Variables:
 - **Height (Altura):** Variable independiente.
 - **Weight (Peso):** Variable dependiente.
 - **Objetivo:** Predecir el peso basado en la altura usando regresión lineal.

Conclusiones y Reflexión Final

- **Recapitulación:**

- ¿Qué es la regresión lineal?
- Función de costo (Cost function) y descenso por gradiente (Gradient Descent).
- Métricas para evaluar modelos de regresión.