Introducción a ML y Generative AI

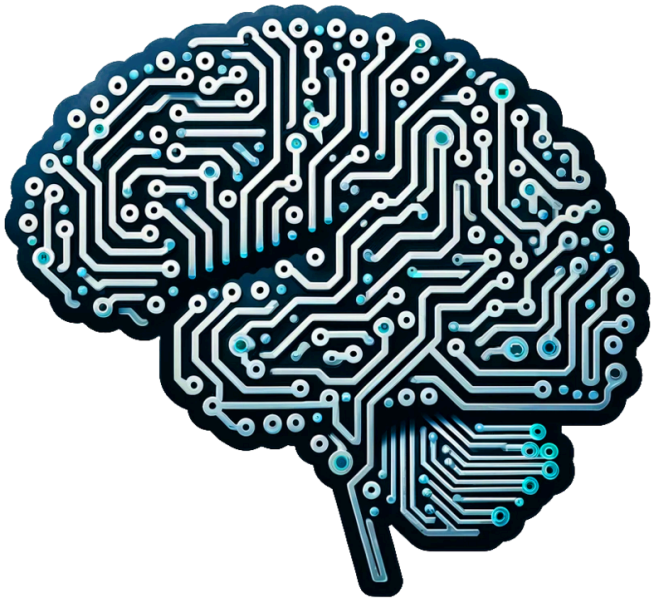

Taller de programación #3

Descripción

Aplicar un flujo completo de clasificación utilizando el dataset del Titanic, desde la división de datos hasta la evaluación e interpretación de un modelo de k-NN (k-Nearest Neighbors). Los estudiantes seguirán estos pasos prácticos para entender cómo funciona el modelo y cómo ajustar su rendimiento.

1. Herramientas :

- **Python**: versión 3.11
- **VSCode**: con soporte para Jupyter Notebooks
- **Bibliotecas**: pandas, scikit-learn, matplotlib, seaborn

2. Preparando el Titanic Dataset para clasificación

- Asegúrate de eliminar o imputar valores faltantes.
- Selecciona características relevantes para la predicción (por ejemplo, Pclass, Sex, Age, Fare).
- Convierte las variables categóricas en numéricas (como Sex).
- Define los features y los labels

```
import pandas as pd

# Cargar el dataset
df = pd.read_csv('titanic.csv')
```

```
# Definir características y etiquetas
X = df[['Pclass', 'Sex', 'Age', 'Fare']]
y = df['Survived']
```

3. División de datos en entrenamiento y prueba

- Divide los datos en un 80% de entrenamiento y 20% de prueba. Usa una semilla aleatoria fija (por ejemplo, random_state=42) para asegurar que los resultados sean replicables.

- Para esta tarea puedes usar la función train_test_split con el comando (https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html):

from sklearn.model_selection import train_test_split

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X,
                                                    y,
                                                    test_size=0.2,
                                                    random_state=42)
```

4. Entrenar el modelo k-NN con datos de entrenamiento

- Entrena un modelo de k-Nearest Neighbors (k-NN) utilizando el conjunto de entrenamiento con un valor inicial de k=3.
- Puedes utilizar KneighborsClassifier (https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html)

```
from sklearn.neighbors import KNeighborsClassifier

# Entrenar modelo k-NN con k=3
knn = KNeighborsClassifier(n_neighbors=3)
knn.fit(X_train, y_train)
```

5. Realizar predicciones en el conjunto de prueba

- Usa el modelo entrenado para predecir las etiquetas del conjunto de prueba.

```
# Hacer predicciones en el conjunto de prueba
y_pred = knn.predict(X_test)
```

6. Evaluar el modelo con diferentes valores de k

- Evalúa el modelo con diferentes valores de k (prueba valores como 1, 3, 5, 7, 9).
- Observa cómo el valor de k afecta las métricas de evaluación: Exactitud, Precisión, Recall, y F1-Score.
- Puedes utilizar accuracy_score, precision_score, recall_score, f1_score de la librería scikit-learn (https://scikit-learn.org/stable/api/sklearn.metrics.html#classification-metrics)
- Elige el mejor valor de k.

```
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

# Probar diferentes valores de k y evaluar el rendimiento
for k in [1, 3, 5, 7, 9]:
    knn = KNeighborsClassifier(n_neighbors=k)
    knn.fit(X_train, y_train)
    y_pred = knn.predict(X_test)

    print(f"k = {k}")
    print(f"Exactitud: {accuracy_score(y_test, y_pred)}")
    print(f"Precisión: {precision_score(y_test, y_pred)}")
    print(f"Recall: {recall_score(y_test, y_pred)}")
    print(f"F1-Score: {f1_score(y_test, y_pred)}")
    print("--------------------------")
```

7. Crea y analiza la Matriz de Confusión utilizando tu mejor k.

- Crea una Matriz de Confusión y explora cómo se distribuyen los errores de clasificación.
- Visualiza la matrix utilizando la librería seaborn (https://seaborn.pydata.org/generated/seaborn.heatmap.html)
- Interpreta los resultados de la matriz (¿Cuántos falsos positivos y falsos negativos hay?).
- Puedes utilizar confusion_matrix de scikit-learn (https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html)

```python
from sklearn.metrics import confusion_matrix
import seaborn as sns
import matplotlib.pyplot as plt

# Crear la matriz de confusión
cm = confusion_matrix(y_test, y_pred)

# Visualizar la matriz
sns.heatmap(cm, annot=True, fmt="d", cmap="Blues")
plt.xlabel('Predicción')
plt.ylabel('Real')
plt.title('Matriz de Confusión')
plt.show()

# Interpretación
tn, fp, fn, tp = cm.ravel()
print(f"Verdaderos Negativos: {tn}, Falsos Positivos: {fp}")
print(f"Falsos Negativos: {fn}, Verdaderos Positivos: {tp}")
```

8. Crea y analiza la Matriz de Confusión utilizando tu mejor k.

- ¿Cuál fue el mejor valor de k?
- ¿Cómo cambió el rendimiento del modelo a medida que ajustaste el valor de k?
- ¿Qué métrica (precisión, recall, F1-score) crees que es más importante para este problema? ¿Por qué?
- Analiza la Matriz de Confusión. ¿Cómo afecta la cantidad de falsos positivos y falsos negativos a la interpretación del modelo?

Marcel Mauricio Moran Calderon
marcel_moran41@hotmail.com

Ariel Ramos Vela
ariel.ramos97@gmail.com